

PREDICCIÓN DE PRECIOS DE VIVIENDAS

Sistema de Información · Fase 2

Tema	Predicción de Precios de Viviendas
Tipo	Aprendizaje Supervisado — Regresión
Algoritmos	Regresión Lineal · KNN · SVM · Árbol de Decisión
Dataset	boston_housing_esp.csv (1,728 registros)
Tecnologías	Python 3 · Flask · scikit-learn · matplotlib
Fecha	18 de May de 2026

Repositorio: github.com/Rodrigoss06/PROYECTO-FASE2-SIA

1. Descripción del Proyecto

El proyecto implementa un **Sistema de Información con aprendizaje supervisado** para predecir el precio de viviendas residenciales. Se aplican cuatro algoritmos de regresión sobre un dataset de propiedades inmobiliarias, comparando su rendimiento mediante métricas estándar (R^2 , RMSE, MAE) y exponiendo los resultados a través de una interfaz web interactiva desarrollada con Flask.

El usuario puede: (a) ejecutar cada algoritmo individualmente y visualizar métricas y gráficos, (b) comparar los cuatro modelos simultáneamente, y (c) ingresar los datos de una propiedad concreta mediante un formulario validado para obtener el precio estimado de todos los modelos.

1.1 Dataset

Campo	Valor
Archivo	boston_housing_esp.csv
Registros	1,728
Características	15
Variable objetivo	precio (USD)
Precio mínimo	\$5,000
Precio máximo	\$775,000
Precio promedio	\$211,966

Las 15 características incluyen variables numéricas (metros habitables, antigüedad, precio del terreno, dormitorios, baños, chimeneas, habitaciones totales, porcentaje de universitarios en la zona) y variables categóricas codificadas (tipo de calefacción, combustible, sistema de desagüe, vistas al lago, nueva construcción, aire acondicionado).

2. Arquitectura del Sistema

El sistema sigue una arquitectura cliente-servidor de tres capas:

Capa	Tecnología	Responsabilidad
Presentación	HTML5 + CSS3 + JS	Interfaz web, formularios, validación front-end
Lógica de negocio	Python 3 · Flask	Endpoints REST, validación back-end, ML
Datos	CSV + scikit-learn	Dataset, preprocesamiento, modelos en memoria

Endpoints REST implementados:

Método	Ruta	Descripción
--------	------	-------------

GET	/api/regresion_lineal	Métricas + gráficos de Regresión Lineal
GET	/api/knn	Métricas + gráficos de KNN (k=5)
GET	/api/svm	Métricas + gráficos de SVM (kernel RBF)
GET	/api/arbol	Métricas + gráficos de Árbol de Decisión
GET	/api/comparacion	Tabla comparativa de los 4 algoritmos
POST	/api/predecir	Predicción interactiva con datos de usuario
GET	/api/dataset_info	Estadísticas del dataset

3. Algoritmos de Machine Learning

3.1 Regresión Lineal

Modelo paramétrico que ajusta un hiperplano minimizando el error cuadrático medio (OLS). Asume linealidad entre características y precio. Rápido, interpretable y útil como línea base. Se aplica StandardScaler antes del ajuste para normalizar las magnitudes.

R ² Score	RMSE	MAE
60.05%	\$68,442	\$45,476




Figura: Métricas de rendimiento — Regresión Lineal



Figura: Ajuste del modelo y correlación de características

3.2 K-Nearest Neighbors (k=5)

Algoritmo no paramétrico que predice el precio promediando los k=5 vecinos más similares en el espacio de características normalizado. No genera un modelo explícito: almacena todos los datos de entrenamiento.

R ² Score	RMSE	MAE
58.27%	\$69,950	\$45,500




Figura: Métricas de rendimiento — K-Nearest Neighbors ($k=5$)




Figura: Ajuste del modelo y correlación de características

3.3 Support Vector Machine (RBF)

Busca el hiperplano que mejor se ajusta a los datos con un margen de tolerancia ϵ , usando el kernel RBF para capturar relaciones no lineales. Parámetros: $C=100$, $\gamma=\text{auto}$. Requiere escalado estricto de las características.

R² Score	RMSE	MAE
2.25%	\$107,058	\$69,375




Figura: Métricas de rendimiento — Support Vector Machine (RBF)



Figura: Ajuste del modelo y correlación de características

3.4 Árbol de Decisión (max_depth=10)

Construye un árbol binario de reglas de decisión basadas en umbrales de características. No requiere escalado. Altamente interpretable: cada nodo representa una regla sobre una característica. max_depth=10 controla el sobreajuste.

R² Score	RMSE	MAE
53.44%	\$73,886	\$48,823




Figura: Métricas de rendimiento — Árbol de Decisión (max_depth=10)




Figura: Estructura del Árbol de Decisión e importancia de características

4. Comparación de Algoritmos

Algoritmo	R ² Score	RMSE	MAE	Escalado
Regresión Lineal	60.05%	\$68,442	\$45,476	Sí
KNN (k=5)	58.27%	\$69,950	\$45,500	Sí
SVM (RBF)	2.25%	\$107,058	\$69,375	Sí
Árbol Decisión	53.44%	\$73,886	\$48,823	No

El algoritmo con mayor R² es **Regresión Lineal** (60.05%). La Regresión Lineal supera ligeramente a KNN en este dataset, ambos en torno al 58–60%. El SVM con parámetros actuales muestra bajo rendimiento; con grid search sobre C y γ podría mejorar. El Árbol de Decisión es el más interpretable aunque con R² menor.




Figura: Comparación R² Score (%) entre los 4 algoritmos

5. Predicción Interactiva (Caso de Uso)

Se ejecutó una predicción de ejemplo a través del endpoint **POST /api/predecir** con los siguientes datos de una propiedad tipo:

Característica	Valor	Característica	Valor
Metros habitables	1,800 sq ft	Dormitorios	3
Metros totales	0.5 acres	Habitaciones	7
Precio terreno	\$60,000	Baños	2
Antigüedad	15 años	Chimeneas	1
Universitarios	50%	Aire acondicionado	No
Calefacción	Agua/vapor	Nueva construcción	No
Combustible	Gas	Desagüe	Público

Algoritmo	Precio Predicho
-----------	-----------------

KNN (k=5)	\$204,598
Regresión Lineal	\$235,827
SVM (RBF)	\$192,383
Árbol de Decisión	\$380,000
PROMEDIO	\$253,202

Precio estimado promedio: \$253,202

6. Validaciones y Buenas Prácticas

6.1 Validación de datos (doble capa)

Capa	Tipo	Descripción
Front-end (JS)	Campos requeridos	Todos los campos deben completarse antes de enviar
Front-end (JS)	Rangos numéricos	Valida min/max por campo (metros, años, precio, etc.)
Front-end (JS)	Regla de negocio	Habitaciones totales $\geq$ dormitorios
Front-end (JS)	Selects vacíos	Los dropdowns deben tener opción seleccionada
Back-end (Py)	Campos faltantes	Retorna 400 si falta algún campo requerido
Back-end (Py)	Rangos numéricos	Retorna 422 con mensaje de error detallado
Back-end (Py)	Opciones categóricas	Valida contra lista blanca de valores permitidos

6.2 Buenas prácticas implementadas

- Separación de responsabilidades: lógica ML en backend, presentación en frontend.
- Caché de modelos: los 4 modelos se entrenan una sola vez al inicio y se reutilizan en cada request.
- Manejo de errores: try/except en todos los endpoints con respuestas JSON descriptivas.
- Preprocesamiento consistente: el mismo StandardScaler y LabelEncoders del entrenamiento se aplican en predicción.
- Valores nulos: np.nan_to_num() garantiza que el dataset no tenga NaN antes del entrenamiento.
- Respuestas HTTP semánticas: 400 (campos faltantes), 422 (validación fallida), 500 (error interno).

7. Resultados y Conclusiones

Los cuatro algoritmos fueron evaluados sobre el 20% del dataset (346 registros) reservado para prueba, con el 80% restante (1,382 registros) para entrenamiento (random_state=42).

Algoritmo	R ²	RMSE	MAE	Interpretabilidad	Velocidad
Regresión Lineal	60.05%	\$68,442	\$45,476	Alta	Muy rápido
KNN (k=5)	58.27%	\$69,950	\$45,500	Baja	Lento en prod.
SVM (RBF)	2.25%	\$107,058	\$69,375	Baja	Lento en entreno
Árbol Decisión	53.44%	\$73,886	\$48,823	Alta	Rápido

1. **Regresión Lineal es el mejor modelo** en este dataset ($R^2=60.05\%$, $RMSE=\$68,441$, $MAE=\$45,475$). Su simplicidad resulta ser una ventaja porque el precio tiene componentes aproximadamente lineales respecto a metros habitables, precio del terreno y antigüedad.
2. **KNN obtuvo resultados similares** ($R^2=58.27\%$), confirmando que la similitud espacial captura bien los patrones locales de precios. Su mayor limitación es la velocidad en datasets grandes.
3. **SVM (RBF) tuvo el rendimiento más bajo** ($R^2=2.25\%$), indicando que los hiperparámetros $C=100$ y $\gamma=\text{auto}$ no son óptimos para este dataset. Con grid search podría mejorar significativamente.
4. **Árbol de Decisión ($R^2=53.44\%$)** ofrece la mejor interpretabilidad con reglas explícitas. Es el modelo más útil para explicar decisiones a usuarios no técnicos.
5. **Para producción** se recomienda usar Regresión Lineal como modelo principal y mostrar el promedio de los 4 algoritmos (como ya hace el sistema) para dar un rango más robusto.

Informe generado automáticamente el 18/05/2026 mediante el sistema en producción.